王宇涛 Yutao Wang

北京大学信息科学技术学院 · 图灵班本科生

2500013209@stu.pku.edu.cn
github.com/wytpku
wytpku.github.io

教育背景

北京大学 · 信息科学技术学院 · 图灵班 2025 — 至今

本科。核心课程：高等代数、数学分析、计算概论 A、程序设计实习（实验班）。

研究兴趣

机器学习理论、统计学习与优化；大模型推理系统、KV Cache、GPU Attention，以及调度与可复现基准评估。

科研与项目

非连续 KV Cache 复用与 GPU Attention 优化

vLLM / FlashInfer / CUDA

- 实现非连续 KV Cache 复用与 packed-query 执行，贯通缓存安装、worker 输入、Attention metadata 与输出回填，支持 dense/MSA 混合 batch。
- 开发逐行位置 mask 与短段分组策略，保留原始 token 位置和 causal 语义。在 H20、BF16 构造 workload 的 8/16/32 个重算洞场景中，单层 Attention 加速 1.59/2.28/2.68 倍，采用 CUDA event 与 12 轮配对计时。
- 40/40 项 GPU 检查通过，覆盖 FP16/BF16、NHD/HND 与 tile 边界；通过 wrapper 池化和共享 workspace 降低测试峰值显存。

Oracle-MWF：面向未来复用的 KV Cache 淘汰

C++ / Python / pybind11

- 实现 C++ 双索引最小堆，将重计算成本、复用概率与等待折扣转化为双静态键和公共时间偏移，单块增删改与淘汰为 O(log n)。
- 通过 pybind11 接入 Python 管理器与 BlockPool，联动分配、touch、释放、覆盖和 reset，维护空闲物理副本的反向索引。
- 构建 28 个会话、3,197 条请求的冻结合成参考数据与跨会话访问索引，完成摘要、反向映射和 CPU 回放校验。

多后端推理调度与可复现基准评估

ThunderAgent / vLLM / Python

- 搭建四后端 OpenAI 兼容服务与并发回放工具，对比 RR、Sticky-RR 与 ThunderAgent，分析负载均衡和 KV 复用的权衡。
- 适配 ThunderAgent 与 vLLM 0.22.1 生命周期接口，实现 trace-informed CacheWise 基线，贯通请求元数据、scheduler 与 BlockPool。
- 冻结 8 个 Program、243 个 turn 的共享 workload，在 Llama-3.1-8B 上完成 5 组配置、每组 3 次有效重复，统计 TTFT、JCT、吞吐与缓存命中并核对机制日志。

技术能力

编程与工具：C/C++、Python、PyTorch、Linux、Shell、Git、NumPy/Pandas、HTTP/SSE。
系统与 GPU：vLLM、FlashInfer、KV Cache、Paged Attention、Prefill/Decode、packed query；CUDA 基础、GPU 数值校验和组件计时。
研究与表达：英文论文与源码阅读、自动化实验、日志诊断、LaTeX 技术文档。

荣誉奖项

- 中国数学奥林匹克（CMO）银牌 2023
- 高考省前三、北京大学新生奖学金 2025
- 第 40 届全国中学生物理竞赛（CPhO）省级一等奖 2023